


RAG-time

“L'intelligence n'est pas la capacité de stocker des informations, mais de savoir où les trouver.” Albert Einstein



Architecture d'un système d'information d'entreprise intégrant un pipeline RAG. Les progiciels métier (CRM, ERP, SAV, PIM) alimentent un Datalake central qui constitue la base de connaissance unifiée de l'organisation. Un système RAG (Retrieval-Augmented Generation) est implanté sur ce datalake : il indexe les données sous forme de vecteurs et les soumet à un modèle de langage (LLM) pour générer des réponses contextualisées. L'accès aux fonctionnalités RAG est médiatisé par un frontend d'authentification et d'accréditation qui applique des politiques de contrôle d'accès basées sur les rôles (RBAC), garantissant à chaque utilisateur une visibilité limitée à son périmètre de connaissances autorisé.



Introduction du sujet

Dans de nombreuses organisations, les informations utiles à l'activité sont réparties entre plusieurs **progiciels** et plusieurs **espaces documentaires** : ERP pour les achats, ventes et livraisons, CRM pour le suivi client, PIM pour les fiches produits, outil de ticketing pour le support et service après vente, GED ou espaces collaboratifs pour les documents métier. Cette fragmentation rend difficile la recherche d'information, ralentit les équipes et limite la réutilisation des connaissances produites au quotidien.

L'intelligence artificielle générative (GenAI) permet de synthétiser automatiquement des contenus à partir d'immenses banques de données. Cependant, les modèles de langage ne connaissent que leurs données d'entraînement, complètement déconnectées des réalités des entreprises.

Les entreprises recherchent des solutions pour fouiller et trouver des informations directement dans leurs propres bases de connaissances.

Il est possible d'entraîner des modèles de langage (**fine tuning**) sur des données d'entreprise, mais cette opération est coûteuse et doit être répétée dès que de nouvelles connaissances sont produites.

Une approche plus dynamique permet d'exploiter la puissance des modèles de langage sur la masse de données des entreprises, grâce à un système de recherche assistée appelé **RAG (Retrieval-Augmented Generation)**. Un moteur de RAG est capable d'interroger de façon unifiée les données métier et documentaires de l'entreprise, sans réentraînement coûteux.

L'objectif cible d'un RAG d'entreprise, est la mise en place d'un moteur de recherche polyvalent, capable à terme d'explorer plusieurs domaines du SI : tickets de support, historiques de relation client, catalogue produit, commandes, livraisons, procédures, contrats, comptes rendus et autres documents métiers.



Le présent projet couvre la spécification et l'implantation d'un système de RAG au sein du SI d'une entreprise, ainsi que le développement d'un MVP centré sur les tickets de support.

Un jeu de données réaliste de [tickets SAV ou support](#) pourra être utilisé comme point de départ, par exemple le dataset Kaggle Customer Support Tickets Dataset (200K+ Records), qui contient plus de 200 000 tickets structurés couvrant plusieurs domaines de service.

Ce projet vise ainsi la conception d'une solution d'IA appliquée à un contexte professionnel réaliste, dans laquelle le système RAG peut fonctionner a minima comme un moteur de recherche classant des résultats, et de manière optionnelle comme un assistant conversationnel capable de reformuler ou synthétiser les résultats récupérés grâce à un LLM.

Mise en situation professionnelle

L'entreprise fictive **LogiStore** est une société en croissance disposant de plusieurs outils métiers déjà en place. Son système d'information repose sur des progiciels distincts pour la gestion commerciale, la relation client, la gestion du catalogue produit, les achats, les ventes, la logistique et le support utilisateur. L'entreprise stocke également un volume important de documents dans différents espaces numériques : procédures internes, guides techniques, fiches produits, contrats, comptes rendus de support, FAQ et documents de référence.



La direction de LogiStore souhaite disposer d'un **outil unifié permettant aux équipes métier et support de retrouver rapidement des informations** , en commençant par le suivi des tickets de support SAV.

À court terme, elle souhaite un **MVP focalisé sur les tickets de support** afin de valider la faisabilité technique, la qualité de la recherche et l'intégration au SI.

À moyen terme, elle souhaite que cette même architecture puisse être étendue à d'autres données du SI, notamment ERP, CRM, PIM et GED.

Dans le cadre du développement de ce MVP, la recherche d'informations se fera selon plusieurs axes:

- par thématique,
- par client,
- par solution,
- par produit,
- par incident,
- par catégorie,
- par historique de résolution.

Le client ne demande pas nécessairement un chatbot complet dès la première version. Le besoin minimal est celui d'un moteur de recherche d'entreprise capable d'**afficher des résultats classés selon leur pertinence**, avec une logique de **ranking** explicable. Une couche de reformulation ou de synthèse par LLM peut être ajoutée en option pour enrichir l'expérience utilisateur.



Vous faites partie d'une équipe de développeurs spécialistes en IA. Vous disposez d'une **clé API OpenRouter** qui vous donne accès à des **modèles de langage** et des **modèles de plongement sémantique (embeddings)**. Les briques d'**indexation textuelle et sémantique** devront reposer sur des technologies open source, couramment utilisées dans ce type d'usage.

Votre équipe de trois développeurs-consultants est chargée de **cadrer le besoin, envisager les risques, proposer l'architecture cible, réaliser le MVP, étudier l'intégration dans le SI et formuler une stratégie d'évaluation des résultats du système RAG**.

Travaux à réaliser

Vous allez réaliser les travaux suivants, sur une période de 10 jours.

Veille métier

- **Rédiger une note de veille technologique décrivant**
 - l'indexation sémantique par plongement
 - les différentes sortes de RAG
 - les techniques d'évaluation des solutions de RAG et métriques associées
- **Étudier le besoin métier et identifier les usages cibles** d'un moteur de recherche RAG en entreprise, en distinguant les besoins à court terme (tickets de support) et les extensions possibles à moyen terme (ERP, CRM, PIM, GED, SAV, documents métiers).



- Réaliser une **étude du système d'information** existant en supposant l'existence de progiciels d'entreprise tels qu'un ERP, un CRM, un PIM, une solution de ticketing et un ou plusieurs espaces de stockage documentaire. Votre veille informationnelle vous mènera à considérer des briques progicielles **on-premise**, en **cloud**, ou hybrides.
- Produire un **schéma d'architecture d'un système RAG d'entreprise au sein d'un SI**, en positionnant les différentes **sources**, le **pipeline d'ingestion**, les **mécanismes d'indexation (sémantique versus full-text)**, la couche de recherche, le service d'accès aux modèles de langage et de plongement, ainsi que le frontend utilisateur.

Développement du MVP

- **Concevoir l'intégration d'un système RAG dans ce SI**, en distinguant clairement les étapes d'ingestion, de prétraitement, de segmentation, d'indexation textuelle et sémantique, de recherche, de ranking et, éventuellement, de reformulation par LLM.
- **Développer un MVP** centré sur les tickets de support à partir d'un dataset public réaliste. Le système devra permettre de rechercher des informations par thème, par client, par solution, par catégorie ou par mots-clés métier, et **présenter les résultats avec un classement de pertinence comparable à celui d'un moteur de recherche**.
- Concevoir un frontend léger de consultation, par exemple en Streamlit ou via une technologie équivalente, afin d'interroger le moteur, visualiser les résultats, filtrer les recherches et afficher les éléments de contexte utiles au classement.



- Prévoir, de manière optionnelle, une **couche de reformulation ou de synthèse par LLM** à partir des résultats les mieux classés.
- Proposer un **mécanisme de recherche hybride** combinant recherche textuelle et recherche sémantique à l'aide de technologies open source. Une solution couramment utilisée pour ce type d'usage pourra être **OpenSearch** ou **Qdrant**, qui permettent de combiner indexation classique, recherche plein texte et recherche vectorielle dans un même moteur.
- **Décrire les modalités d'intégration future** des données ERP, CRM, PIM, documents et historiques SAV dans la même architecture, même si toutes ces sources ne sont pas implémentées dans le MVP.
- **Réaliser une étude de risque** couvrant notamment les données sensibles, la qualité des réponses, les hallucinations éventuelles, la pertinence des résultats, la dépendance à l'API externe, la latence, les coûts et la maintenabilité de la solution.
- Décrire une **stratégie d'industrialisation** minimale de la solution : scripts d'ingestion automatisés, pipeline d'actualisation des index, séparation des composants, configuration, documentation et déploiement local ou sur environnement dédié.
- Proposer une **solution d'évaluation du système RAG**. Cette évaluation pourra inclure des métriques classiques de recherche d'information, un jeu de requêtes de test métier, ainsi qu'un mécanisme de type **LLM as a judge** pour estimer la pertinence, la complétude et la fidélité des réponses ou des résultats retournés.



Compétences visées

Construction et déploiement de solutions d'IA

Les étudiants devront démontrer leur capacité à concevoir une solution d'IA avancée reposant sur un pipeline RAG combinant indexation, recherche et exploitation d'un LLM accessible via API. Ils devront également montrer leur aptitude à structurer les composants logiciels, automatiser les traitements principaux et préparer une solution exploitable dans un cadre professionnel.

Architecture et intégration dans le SI

Le projet devra faire apparaître explicitement le positionnement du moteur RAG dans la cartographie du système d'information. Les étudiants devront identifier les sources documentaires et transactionnelles, les interfaces avec les progiciels existants, éventuellement par la mise en place d'un datalake, les mécanismes d'indexation, les couches d'accès utilisateur et les choix technologiques liés à la recherche textuelle, à la recherche vectorielle et à l'orchestration de la réponse.

Analyse d'opportunité et gestion des risques

Les étudiants devront être capables d'analyser l'intérêt métier d'un moteur de recherche d'entreprise augmenté par l'IA, de prioriser les cas d'usage, de proposer une feuille de route réaliste à partir d'un MVP, puis d'identifier les risques fonctionnels, techniques, économiques et organisationnels liés au projet. L'étude devra notamment aborder la valeur métier, l'acceptabilité par



les utilisateurs, les limites du périmètre et les conditions de généralisation à l'échelle du SI.

Sécurité et protection des données

L'étude devra prendre en compte la sensibilité potentielle des données manipulées, qu'il s'agisse des tickets, des informations client, des références produits ou des documents internes. Les étudiants devront expliciter les principes de filtrage, de cloisonnement, de maîtrise des traces, de limitation de l'exposition des données aux API externes et de protection des secrets d'accès.

Rendu

Le rendu attendu comprend les éléments suivants, sur dépôt GIT :

- Un **rapport de veille technologique**, qui couvre votre étude des solutions RAG et des notions évoquées plus haut.
- Un **document de cadrage** présentant le besoin métier, le contexte SI, le périmètre du MVP et la trajectoire d'extension vers un moteur RAG d'entreprise plus large.
- Un **schéma d'architecture du système d'information avec intégration du système RAG**, faisant apparaître les sources, les flux, les composants logiciels, le frontend, le pipeline d'ingestion, l'indexation et la recherche, dans un SI supposant l'existence de progiciels ERP, CRM, PIM, ticketing et GED.



Dans une logique d'extension, les étudiants devront également décrire comment la base de connaissances pourrait intégrer à terme :

- des données ERP liées aux commandes, ventes, achats et livraisons ;
- des données CRM liées aux clients, interactions et segmentations ;
- des données PIM liées aux produits, familles, caractéristiques et solutions ;
- des documents métier stockés dans une GED ou dans des espaces collaboratifs ;
- des connaissances issues du support et du SAV.

La préparation de cette base de connaissances devra distinguer clairement les données structurées, les données textuelles et les documents non structurés, ainsi que les mécanismes d'enrichissement, de segmentation, d'indexation et de mise à jour nécessaires à un fonctionnement automatique du moteur de recherche RAG.

- Une **étude de risque** argumentée.
- Un **MVP fonctionnel centré sur la recherche dans des tickets de support, avec ranking des résultats et interface de consultation.**
- Une **description du mécanisme de recherche hybride et des technologies choisies.**
- Une **proposition d'évaluation du système**, incluant un protocole de test et une piste de type **LLM as a judge**.
- Un **dépôt Git documenté** contenant le code, la configuration, les scripts utiles et les instructions d'exécution.



- Une **démonstration orale** permettant de présenter le fonctionnement du moteur, la logique d'architecture, les résultats obtenus et les perspectives d'extension.

Base de connaissances

Voici une première sélection de références essentielles, organisées par thématique, avec titre, mini-description et lien.

RAG et architectures RAG

1. **Retrieval-Augmented Generation for Large Language Models**

Survol détaillé des variantes de RAG (naïf, avancé, modulaire), des briques retrieval/generation/augmentation et des enjeux d'évaluation.

<https://arxiv.org/abs/2312.10997>

2. **Retrieval-Augmented Generation: A Comprehensive Survey**

Synthèse récente des travaux RAG, incluant limites des LLM "purs", défis de qualité de retrieval, robustesse et efficacité du pipeline.

<https://arxiv.org/abs/2506.00054>

3. **A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models**

Vue d'ensemble RA-LLMs avec focus sur les aspects techniques (architecture, optimisation, scénarios applicatifs).

<https://arxiv.org/abs/2405.06211>



4. **RAG-Survey (GitHub)**

Repo qui collecte et catégorise les papiers RAG (retrievers, reranking, hybrid search...), utile comme porte d'entrée bibliographique.

<https://github.com/hymie122/RAG-Survey>

Évaluation, LLM-as-a-Judge, benchmarks

1. **Evaluating RAG with LLM as a Judge (Mistral AI)**

Article de blog décrivant le cadre "RAG Triad" et l'usage d'un LLM juge pour scorer contexte, fidélité et pertinence des réponses.

<https://mistral.ai/news/llm-as-rag-judge>

2. **Evaluating RAG systems with synthetic data and LLM judge**

Billet qui fait le tour des stratégies d'évaluation RAG (end-to-end, claim-based...) et illustre l'usage d'un LLM comme juge automatique.

<https://modulai.io/blog/evaluating-rag-systems-with-synthetic-data-and-llm-judge/>

3. **Open RAG Benchmark (Vectara)**

Benchmark open source pour évaluer des systèmes RAG (centré PDF multimodaux) avec protocole de test et métriques reproductibles.

<https://github.com/vectara/open-rag-bench>

Recherche d'entreprise, désilotage, RAG/LLM dans le SI

1. **AI Enterprise Search: The Solution to Information Silos**

Article expliquant comment la recherche d'entreprise pilotée par IA connecte des sources multiples et casse les silos d'information.

<https://www.moveworks.com/us/en/resources/blog/how-ai-enterprise-search-overcomes-information-silos>



2. **What are knowledge silos and why they matter**

Introduction claire au concept de silos de connaissance et au rôle du “unified search index” dans un SI fragmenté.

<https://www.glean.com/perspectives/knowledge-silos-are-out-unified-search-is-in>

Gouvernance, architecture SI, données d'entreprise

1. **The beautiful tango between Data Governance and Enterprise**

Architecture

Article qui montre pourquoi gouvernance des données et architecture d'entreprise doivent être pensées conjointement.

<https://www.linkedin.com/pulse/beautiful-tango-between-data-governance-enterprise-wiersma-cdmp--bvbve>

2. **Enterprise Data Governance: Frameworks and Workflows for Scale**

Vue d'ensemble des modèles de gouvernance (dont fédéré), rôles et priorisation des domaines à gouverner dans une grande organisation.

<https://atlan.com/enterprise-data-governance/>

Indexation textuelle et sémantique open source (OpenSearch)

1. **Semantic search – OpenSearch Documentation**

Documentation officielle sur la recherche sémantique dans OpenSearch (embeddings, index vectoriels, workflows automatisés).

<https://docs.opensearch.org/latest/vector-search/ai-search/semantic-search/>



2. **Vector search – OpenSearch Documentation**

Présentation des capacités de recherche vectorielle et de la combinaison BM25 + vecteurs dans OpenSearch.

<https://docs.opensearch.org/latest/vector-search/>

3. **OpenSearch semantic search: The basics and a quick tutorial**

Tutoriel pédagogique expliquant le fonctionnement de la recherche sémantique et la mise en place pratique dans OpenSearch.

<https://www.instaclustr.com/education/opensearch/opensearch-semantic-search-the-basics-and-a-quick-tutorial-2026-guide/>

Dataset de tickets pour le MVP

1. **Customer Support Tickets Dataset (200K+ Records)**

Dataset Kaggle de plus de 200 000 tickets de support structurés, adapté à un MVP RAG sur environnement “entreprise/SAV”.

<https://www.kaggle.com/datasets/mirzayasirabdullah07/customer-support-tickets-dataset-200k-records>